

# RAPPORT DE PROJET — Analyse et Détection de Profils Vulnérables au Phishing

## 1. Introduction

Dans le cadre de ce projet, nous avons travaillé sur un jeu de données fictif issu d'une campagne de phishing pédagogique.

L'objectif était double :

1. **Analyser les données** pour identifier quels profils sont les plus susceptibles de cliquer sur une attaque de phishing.
2. **Construire une attaque fictive et pédagogique** ciblant le profil le plus vulnérable identifié.

Pour cela, un travail de nettoyage, exploration, visualisation et interprétation des données a été mené avant de proposer un scénario de phishing réaliste.

## 2. Importation et exploration des données

Le dataset result.csv est constitué de 519 lignes et 8 colonnes :

- age
- gaming\_interest\_score
- insta\_design\_interest\_score
- football\_interest\_score
- recommended\_product
- canal\_recommande
- campaign\_success
- Id

Un premier aperçu (head(), info(), describe()) a permis de détecter plusieurs incohérences :

- **Âges impossibles** (entre 2 et 15 ans).
- **Scores anormaux** (de -100 à 740 alors que l'échelle logique est 0–100).

- **Variantes d'écriture** pour les canaux et produits (Mail, MAIL, insta, fornite, etc.).
- **Valeurs inutilisables** ou bruitées (test, nan).

Ces incohérences imposaient un nettoyage approfondi.

## 3. Nettoyage des données

### 3.1 Normalisation

- Passage en minuscules
- Suppression des espaces
- Uniformisation des catégories (mail, instagram, facebook, non\_defini)
- Correction des fautes (fornite → fortnite)
- Transformation de campaign\_success en booléen (True / False)

### 3.2 Détection et suppression des valeurs aberrantes

Les règles suivantes ont été appliquées :

- **Age** accepté uniquement entre **16 et 60 ans**
- Scores d'intérêt acceptés uniquement entre **0 et 100**

Résultat :

- **15 lignes anormales supprimées**
- Dataset final : **499 lignes propres**

Ce dataset propre est appelé **df\_model**.

## 4. Analyse descriptive

### 4.1 Taux de réussite global

**69.74%**

Ce taux très élevé confirme la présence de patterns exploitables.

## 4.2 Taux de réussite par canal

Canal	Taux
Facebook	85.16%
Mail	66.34%
Instagram	63.06%
Non défini	44.44%

➔ **Facebook** est de loin le canal le plus vulnérable.  
C'est un signal extrêmement fort.

## 4.3 Taux de réussite par produit

Produit	Taux
FIFA	72.25%
Fortnite	70.22%
Instagram Pack	66.22%

➔ Le thème **football/FIFA** est le plus efficace.  
Dans un cadre réaliste : FIFA  $\approx$  *contenu lié au football*.

## 4.4 Taux de réussite par tranche d'âge

Tranche	Taux
50-60	78.57%
40-49	71.43%
30-39	70.63%
25-29	68.60%
20-24	66.07%
16-19	57.78%

➔ Les **50-60 ans** sont la tranche la plus vulnérable.

## 4.5 Visualisations

Les graphiques réalisés (barplots + heatmap) montrent clairement :

- La domination de Facebook comme canal vulnérable
- Le rôle du thème "football"

- Une vulnérabilité croissante avec l'âge
- Une corrélation légère mais réelle entre centres d'intérêt et taux de clic

## 5. Analyse corrélative

La heatmap montre des corrélations faibles mais cohérentes :

- **football\_interest\_score** → **+0.10**
- **insta\_design\_interest\_score** → **+0.13**
- **gaming\_interest\_score** → **+0.06**
- **âge** → **+0.06**

### Analyse par niveaux d'intérêt :

- FOOT élevé : **76.44%**
- GAMING élevé : **74.42%**
- INSTAGRAM élevé : **79%**

➔ Les centres d'intérêt (notamment foot) **augmentent significativement la probabilité de clic.**

## 6. Définition du profil le plus vulnérable

En croisant **toutes** les analyses (canal + produit + âge + intérêts), on obtient :

### Profil vulnérable final :

**Utilisateur de 50–60 ans, actif sur Facebook, ayant un fort intérêt pour le football.**

Explication :

- Facebook est leur canal principal
- Le thème “football” est très engageant
- La tranche d'âge 50–60 est la plus sensible aux campagnes
- Les scores d'intérêt foot augmentent la probabilité de clic

- Dans la réalité, cette tranche est très fan de sport / actualités sportives

Ce profil est cohérent **statistiquement ET réaliste socialement**.

## 7. Scénario d'attaque fictive (datatelling)

Nous imaginons maintenant une attaque **fictive et pédagogique**.

### Cible :

Personne de 50–60 ans, fan de football, présente quotidiennement sur Facebook.

#### - Message d'attaque :

" 🎟️ **Billets VIP Ligue des Champions à -80% !**  
**Offre exclusive réservée aux abonnés Facebook.**  
**Cliquez ici pour vérifier votre identité et réserver vos places."**

#### - Pourquoi cette attaque est crédible

- Le football est leur centre d'intérêt majeur
- L'offre "exclusivité + réduction" crée un fort effet FOMO
- Facebook est leur plateforme la plus utilisée
- Le design du message imite les pubs sponsorisées classiques
- La cible appartient à la tranche la plus vulnérable du dataset

## 8. Conclusion

Grâce à un nettoyage rigoureux, une analyse détaillée et des visualisations claires, nous avons identifié un profil de cible particulièrement vulnérable :

**Utilisateur Facebook de 50–60 ans, grand fan de football.**

Ces résultats ont permis de construire une attaque fictive, réaliste et basée sur les données, conformément aux objectifs du projet.

Ce travail montre à quel point la data peut révéler des comportements à risque et aider à concevoir des campagnes pédagogiques pour sensibiliser les utilisateurs aux dangers du phishing.